



Министерство науки и высшего образования Российской Федерации
Калужский филиал федерального государственного автономного
образовательного учреждения высшего образования
«Московский государственный технический университет
имени Н.Э. Баумана
(национальный исследовательский университет)»
(КФ МГТУ им. Н.Э. Баумана)

ФАКУЛЬТЕТ ИУК Информатика и управление

КАФЕДРА ИУК4 Программное обеспечение ЭВМ, информационные технологии

ЛАБОРАТОРНАЯ РАБОТА

«ЦЕПОЧКИ MAPREDUCE ЗАДАЧ. СРАВНЕНИЕ ДОКУМЕНТОВ»

по дисциплине: «Технологии обработки больших данных»

Выполнил: студент группы ИУК4-72Б

(Подпись)

Моряков В.Ю.

(И.О. Фамилия)

Проверил:

(Подпись)

Голубева С.Е.

(И.О. Фамилия)

Дата сдачи (защиты):

Результаты сдачи (защиты):

- Балльная оценка:

- Оценка:

Калуга, 2025

Цель: формирование практических навыков использования цепочек MapReduce для решения сложных задач обработки больших данных.

Задачи:

1. Получить навыки реализации цепочки MapReduce задач.
2. Изучить интерфейс Hadoop MapReduce.
3. Изучить алгоритмы анализа, сравнение текстовых документов.
4. Получить практические навыки обработки и анализа текстовых данных.

Задание:

Выполнить задание с помощью цепочки MapReduce задач согласно варианту. В качестве входных текстовых файлов можно использовать книги в txt формате из библиотеки Project Gutenberg: <https://www.gutenberg.org>.

Формулировка задания (17 вариант):

Подсчитать среднюю длину слов в нескольких файлах.

Результат должен содержать средний размер слов в файле и соответствующее название файла. Сохранить результат в файл в виде:

(7@file1 6@file1 13@file2 22@file2 ...).

Ход выполнения:

```
1 <?xml version="1.0"?>
2 <configuration>
3   <property>
4     <name>mapreduce.framework.name</name>
5     <value>yarn</value>
6   </property>
7
8   <property>
9     <name>yarn.app.mapreduce.am.env</name>
10    <value>HADOOP_MAPRED_HOME=/opt/hadoop</value>
11  </property>
12
13  <property>
14    <name>mapreduce.map.env</name>
15    <value>HADOOP_MAPRED_HOME=/opt/hadoop</value>
16  </property>
17
18  <property>
19    <name>mapreduce.reduce.env</name>
20    <value>HADOOP_MAPRED_HOME=/opt/hadoop</value>
21  </property>
22 </configuration>
23
```

Рисунок 1 Изменение конфигурации MAPReduce hadoop

```

Reduce output records=2
Spilled Records=6158
Shuffled Maps =3
Failed Shuffles=0
Merged Map outputs=3
GC time elapsed (ms)=274
CPU time spent (ms)=3040
Physical memory (bytes) snapshot=1140568064
Virtual memory (bytes) snapshot=10858143744
Total committed heap usage (bytes)=1226833920
Peak Map Physical memory (bytes)=286351360
Peak Map Virtual memory (bytes)=2714066944
Peak Reduce Physical memory (bytes)=287854592
Peak Reduce Virtual memory (bytes)=2717687808

Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0

File Input Format Counters
  Bytes Read=22990

File Output Format Counters
  Bytes Written=70

2025-10-08 05:48:30 INFO StreamJob:1029 - Output directory: /output
✓ Результат:
5@hdfs://namenode/input/file1.txt
5@hdfs://namenode/input/file2.txt

```

Рисунок 2 Результаты работы программы

```

bash /init-hdfs.sh
bash /create_files.sh

hadoop jar /opt/hadoop/share/hadoop/tools/lib/hadoop-streaming-*.jar \
  -files /scripts/mapper_avg_wordlen.py,/scripts/reducer_avg_wordlen.py,/scripts/combiner_sum_count.py \
  -input /input \
  -output /output \
  -mapper mapper_avg_wordlen.py \
  -combiner combiner_sum_count.py \
  -reducer reducer_avg_wordlen.py

echo "✓ Результат:"
hdfs dfs -cat /output/part-00000

```

Рисунок 3 Скрипт для запуска

```

Reduce input records=3
Reduce output records=2
Spilled Records=6
Shuffled Maps =3
Failed Shuffles=0
Merged Map outputs=3
GC time elapsed (ms)=264
CPU time spent (ms)=2600
Physical memory (bytes) snapshot=1375899648
Virtual memory (bytes) snapshot=10852098048
Total committed heap usage (bytes)=1497890816
Peak Map Physical memory (bytes)=394129408
Peak Map Virtual memory (bytes)=2712674304
Peak Reduce Physical memory (bytes)=294645760
Peak Reduce Virtual memory (bytes)=2716524544

Shuffle Errors
BAD_ID=0
CONNECTION=0
IO_ERROR=0
WRONG_LENGTH=0
WRONG_MAP=0
WRONG_REDUCE=0

File Input Format Counters
Bytes Read=12616
File Output Format Counters
Bytes Written=70
2025-10-22 06:19:48 INFO StreamJob:1029 - Output directory: /output
✓ Результат:
5@hdfs://namenode/input/file1.txt
3@hdfs://namenode/input/file2.txt
bash-4.2$

```

Рисунок 4 Результаты работы в bash

Листинги программ:

combiner_sum_count.py:

```

#!/usr/bin/env python2
# combiner_sum_count.py

import sys

current_file = None
total_len = 0
word_count = 0

for line in sys.stdin:
    line = line.strip()
    filename, length = line.split('\t')
    length = int(length)

    if current_file and filename != current_file:
        # Output partial sum and count
        print "{0}\t{1},{2}".format(current_file, total_len, word_count)
        total_len = 0
        word_count = 0

    current_file = filename
    total_len += length
    word_count += 1

if current_file:
    print "{0}\t{1},{2}".format(current_file, total_len, word_count)

```

reducer_avg_wordlen.py:

```
#!/usr/bin/env python2
```

```
# reducer_avg_wordlen.py
```

```
import sys
```

```
current_file = None
```

```
total_len = 0
```

```
word_count = 0
```

```
for line in sys.stdin:
```

```
    line = line.strip()
```

```
    if not line:
```

```
        continue
```

```
    try:
```

```
        filename, val = line.split('\t')
```

```
        length_sum, count = map(int, val.split(','))
```

```
    except ValueError:
```

```
        continue # skip malformed lines
```

```
    if current_file and filename != current_file:
```

```
        avg = float(total_len) / word_count if word_count else 0
```

```
        print "{0}@{1}".format(int(avg), current_file)
```

```
        total_len = 0
```

```
        word_count = 0
```

```
    current_file = filename
```

```
    total_len += length_sum
```

```
    word_count += count
```

```
# Print last file
```

```
if current_file:
```

```
    avg = float(total_len) / word_count if word_count else 0
```

```
    print "{0}@{1}".format(int(avg), current_file)
```

mapper_avg_wordlen.py:

```
#!/usr/bin/env python
```

```
# mapper_avg_wordlen.py (Python 2)
```

```
import sys
import os
import re

for line in sys.stdin:
    line = line.strip()
    words = re.findall(r'\w+', line)
    if not words:
        continue
    filename = os.environ.get('map_input_file', 'unknown')
    for word in words:
        print "{0}\t{1}".format(filename, len(word))
```

Вывод: в ходе лабораторной работы были получены практические навыки по работе с MapReduce.